



Kocaeli
Üniversitesi

KÜRESEL GÜNLÜK İKLİM VERİSİ ÜZERİNDE UÇTAN UCA VERİ ANALİZİ

Büyük Veri Analizine Giriş Dönem Projesi Sunumu


220201048 - Adem Alperen ARDA
220201079 - Ubeydullah GÜR
220201027 - Barış CERİT

ÖZET



Kocaeli
Üniversitesi

- Verinin Tanımlanması ve Amaç
- Akan Veriyi Simüle Etmek
 - Docker Kurulumu ve Amacı
 - Kafka Mantığı
 - Spark
- Veri Analizi
 - Exploratory Data Analysis (EDA)
 - Feature Engineering
- Modelleme
 - Makine Öğrenmesi
 - Görselleştirme ve Değerlendirme
- Sonuç




```
root
|-- timestamp: string (nullable = true)
|-- event_type: string (nullable = true)
|-- station_id: string (nullable = true)
|-- city_name: string (nullable = true)
|-- measurement_date: string (nullable = true)
|-- season: string (nullable = true)
|-- avg_temp_c: double (nullable = true)
|-- min_temp_c: double (nullable = true)
|-- max_temp_c: double (nullable = true)
|-- precipitation_mm: double (nullable = true)
|-- snow_depth_mm: double (nullable = true)
```

VERİ VE AMAÇ




Kocaeli
Üniversitesi



Dünya genelindeki 1.234 hava istasyonundan 1750–2023 yılları arasında toplanmış yaklaşık 27.6 milyon günlük hava ölçümünü içeriyor. Her satır; sıcaklık (ortalama, min, max), yağış, kar derinliği, rüzgar hızı ve yönü, basınç ve güneşlenme süresi gibi 14 farklı meteorolojik ölçümü barındırıyor.

Dünkü sıcaklık, son 7 günün ortalaması, mevsim, ay, şehir, yağış vb. biliniyorsa bugünün ortalama sıcaklığı ne olur? sorusu için tahminleme yapmak.



1) AKAN VERİYİ SİMÜLE ETMEK




Kocaeli
Üniversitesi

1.1) Docker



- Projede 7-8 farklı servis var (Kafka, Zookeeper, Spark, Jupyter, MLflow, Streamlit...). Bunların hepsini tek tek bilgisayara kurmak hem zor hem de versiyon çakışmalarına yol açar.



- Pipeline herhangi bir bilgisayarda aynı şekilde çalışır. "Benim makinemde çalışıyordu" sorunu ortadan kalkar.


1) AKAN VERİYİ SİMÜLE ETMEK

1.2) Kafka

- Kafka, gerçek zamanlı veri akışı için kullanılan dağıtık bir mesaj kuyruğu sistemidir. Yani bir taraf veriyi yazar (producer), diğer taraf okur (consumer), Kafka da ortada bu mesajları topic denilen kanallarda saklar.

Buffer gerekli. Neden?

- Kafka burada bir tampon görevi görüyor; üreten ile tüketen sistemleri birbirinden ayırarak, Spark'ın bu veriyi kendi hızında işlemesine olanak tanıyor.



1) AKAN VERİYİ SİMÜLE ETMEK


1.3) Spark

- Projenin işleyici beyni. Kafka'dan veriyi alıp temizleyen, dönüştüren ve Delta Lake'e yazan kısım.

Spark'ın görevi — Medallion Architecture (Bronze → Silver → Gold):

- Bronze:** Kafka'dan gelen ham JSON verisini olduğu gibi kaydeder.
- Silver:** Veriyi temizler (eksikleri doldurur, hatalı satırları atar).
- Gold:** Feature engineering ile ML'e hazır hale getirir.


- Bu Medallion mimarisi sayesinde veri her aşamada izlenebilir ve geri dönülebilir bir şekilde işleniyor.



2) VERİ ANALİZİ

2.1) Exploratory Data Analysis (EDA)

- EDA, veriyi modele vermeden önce tanıma sürecidir. Hangi feature'ların anlamlı olduğunu, hangi temizliklerin gerekli olduğunu burada görürsün.
- Keşifsel Veri Analizi, modelleme sürecinde ve problemi anlamlandırırken büyük kolaylık sağlar. Örnek olarak projemizde EDA sonucunda şu bulgulara ulaştık:



1. VERİ KALİTESİ:

- avg_temp_c: Tam dolu, analiz için güvenilir ana değişken
- min/max_temp_c: %18-25 eksik değer var
- precipitation_mm: %36 eksik
- snow_depth_mm, wind, pressure, sunshine: Kullanılamaz (>%99 eksik)

2. SICAKLIK BULGULARI:

- Ortalama sıcaklık: 18.1°C
- Aralık: -2.1°C ile 37.8°C
- En sıcak ay: Temmuz (~30°C)
- En soğuk ay: Ocak (~5°C)
- Yaz ortalaması: 28.7°C, Kış ortalaması: 6.1°C

3. ZAMAN SERİSİ:

- Veri aralığı: 1957-2010 (53 yıl)
- 1970-1990 arası veri eksikliği var (az kayıt sayısı)
- 2003-2010 arası veri en yoğun dönem

2) VERİ ANALİZİ

2.2) Feature Engineering

- Ham veriden modelin daha iyi öğrenebileceği yeni, anlamlı sütunlar türetme sürecidir. Modelin başarısını doğrudan etkileyen en kritik aşamalardan biridir.
- Toplam 23 sütunluk Gold ML tablosu elde ettik. Özellikle lag ve rolling feature'ları sayesinde model, mevsimsel ve günlük süreklilik örüntülerini öğrenebildi.

Türettiğimiz Veriler

- 🕒 Zamansal
 - day_of_year
 - season_numeric
 - is_weekend
- 🌡️ Sıcaklık türevleri
 - temp_range_c (günlük fark)
 - is_freezing
 - is_hot_day
- ☁️ Yağış
 - precipitation_category
 - is_rainy
- ⏮️ Zaman serisi:
 - temp_lag_1 → dünkü sıcaklık
 - temp_rolling_avg_7d → son 7 günün ortalaması
 - temp_diff_from_yesterday → dünden farkı
 - is_temp_anomaly → sıra dışı sıcaklık mı?


3) MODELLEME

3.1) Makine Öğrenmesi

Hedef: avg_temp_c (günlük ortalama sıcaklık) tahmini = Regresyon problemi

- Kullandığımız 5 model:
 -  Linear Regression
 -  Decision Tree Regressor
 -  Random Forest Regressor
 -  GBT (Gradient Boosted Trees) Regressor
 -  Generalized Linear Regression (GLR)
- Değerlendirme Metrikleri:
 - RMSE → tahmin hatasının büyüklüğü
 - MAE → ortalama mutlak hata
 - R^2 → modelin veriyi açıklama oranı (1'e yakın = iyi)

- Araçlar:
 - Spark MLlib → 27M satırlık veriyi dağıtık olarak eğitebilmek için
 - MLflow → tüm modellerin parametrelerini, metriklerini ve çıktılarını otomatik kaydetmek için




3) MODELLEME

3.2) Görselleştirme ve Değerlendirme

🏆 Kazanan: Linear Regression / GLR

- İki model de neredeyse mükemmele yakın ($R^2 \approx 0.999$) sonuç verdi. Bu, doğrusal modellerin bu problem için yeterli olduğunu gösteriyor.



4) SONUÇ


- Uçtan Uca Pipeline Kurduk Docker, Kafka, Spark ve Delta Lake ile veriyi Bronze → Silver → Gold akışında işledik.
- Veriyi ML'e Hazırladık 27.6M satırlık veriyi EDA ile analiz edip lag ve rolling feature'larla zenginleştirdik.
- 5 Modeli Karşılaştırdık En iyi sonucu Linear Regression ve GLR verdi ($R^2 = 0.9987$).
- Çıkarım İyi feature engineering, karmaşık modele olan ihtiyacı azaltır.





Sorular...

anonymo2239/**Daily-Climate-Big-Data**



End-to-end big data pipeline processing 27.6M rows of global daily climate data with Docker, Kafka, Spark Structured Streaming, Delta Lake...



2

Contributors



0

Issues



0

Stars



0

Forks



anonymo2239/Daily-Climate-Big-Data: End-to-end big data pipeline processing 27.6M rows of global daily climate data with Docker, Kafka,...

End-to-end big data pipeline processing 27.6M rows of global daily climate data with Docker, Kafka, Spark Structured Streaming, Delta Lake (Bronze/Silver/Gold), and MLflow. - anonymo2239/Daily-Clim...



GitHub